

Univerzitet u Zenici

Politehnički fakultet

Odsjek SOFTVERSKO INŽENJERSTVO

Zadaća X

Poslovna inteligencija

Autor:

Ime i prezime, broj indeksa

Sadržaj

1	Izrada zadatka			
	1.1	Zadata	ak 1	. 1
		1.1.1	Obrazloženje	. 1
		1.1.2	Slika	. 2
	1.2	Zadata	ak 2	. 2
		1.2.1	Obrazloženje	. 2
		1.2.2	Slika	. 2
	1.3	Zadata	ak 3	. 3
		1.3.1	Obrazloženje	. 3
		1.3.2	Slika	. 4
	1.4	Zadata	ak 4	. 6
		1.4.1	Obrazloženje	. 6
		1.4.2	Slika	. 7

1. Izrada zadatka

1.1 Zadatak 1

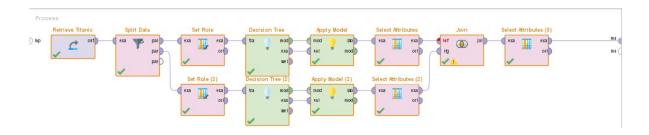
1.1.1 Obrazloženje

Cilj ovog projekta je kreirati i analizirati dva stabla odlučivanja koristeći *Titanic* dataset. Podaci su podijeljeni u omjeru 70:30, gdje je 70% podataka korišteno za treniranje modela, a 30% za testiranje. Analiza uključuje kreiranje stabala odlučivanja, usporedbu njihovih performansi i vizualizaciju predikcija.

Koraci implementacije uključuju:

- Učitavanje *Titanic* skupa podataka kao osnovnog skupa podataka.
- Podjela podataka pomoću operatora Split Data:
 - 70% podataka za treniranje.
 - 30% podataka za testiranje.
- Kreiranje prvog stabla odlučivanja:
 - Definisanje ciljne varijable (Survived) pomoću operatora **Set Role**.
 - Treniranje modela koristeći operator **Decision Tree**.
 - Testiranje modela pomoću operatora **Apply Model**.
- Kreiranje drugog stabla odlučivanja koristeći alternativni pristup s drugačijim parametrima za **Decision Tree**, te testiranje na istih 30% podataka.
- Spajanje predikcija iz oba modela sa stvarnim vrijednostima pomoću operatora Join.
- Filtriranje ključnih atributa (Survived i predikcije) pomoću operatora Select Attributes.

1.1.2 Slika

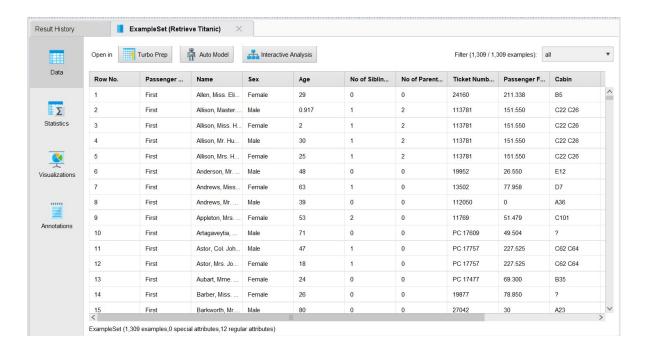


1.2 Zadatak 2

1.2.1 Obrazloženje

Korišten je skup podataka Titanic.

1.2.2 Slika



1.3 Zadatak 3

1.3.1 Obrazloženje

Prvo stablo odlučivanja

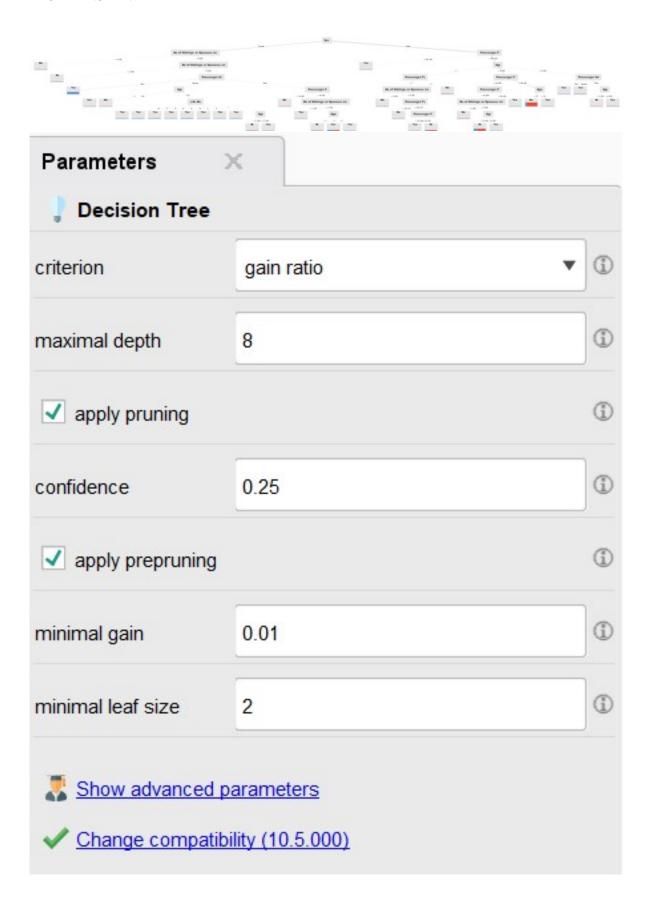
- Kriterij za podjelu: Gain Ratio.
- Maksimalna dubina: 8.
- Primjena obrezivanja: Da (Apply Pruning).
- Povjerenje za obrezivanje: 0.25.
- Ostali parametri: Zadržane su zadane vrijednosti.

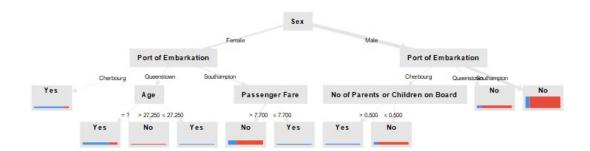
Drugo stablo odlučivanja

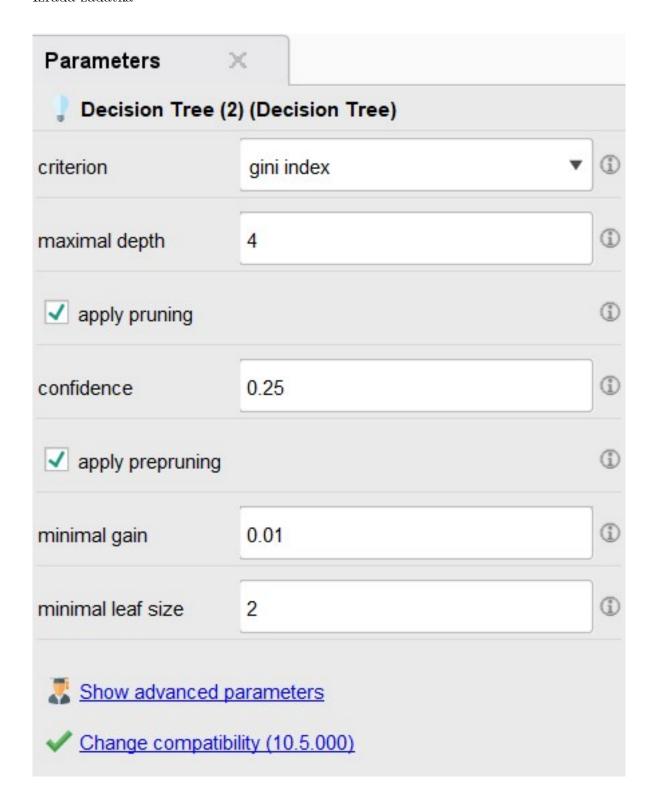
- Kriterij za podjelu: Gini Index.
- Maksimalna dubina: 4.
- Primjena obrezivanja: Da (Apply Pruning).
- Povjerenje za obrezivanje: 0.25.
- Ostali parametri: Zadržane su zadane vrijednosti.

Oba modela su trenirana na 70% podataka i testirana na preostalih 30%. Analizirani su rezultati kako bi se odredila optimalnost različitih parametara za predikciju.

1.3.2 Slika







1.4 Zadatak 4

1.4.1 Obrazloženje

Prikazane predikcije za isti dataset za jedno i drugo stablo.

1.4.2 Slika

